

TECH CHALLENGE - FASE 2

Relatório Técnico

Otimização de Rotas para Distribuição de Medicamentos e Atendimento Especializado à Mulher

Autor: Jonas Euler Paulino de Queiroz

Curso: Pós-graduação em IA para Devs

Instituição: FIAP

Projeto escolhido: Projeto 2

Repositório: <https://github.com/Visheuleer/ia-tech-challenge-2>

Vídeo de apresentação: <https://youtu.be/pLbjqiIZQmY>

Sumário

Relatório Técnico - Otimização de Rotas para Distribuição de Medicamentos e Atendimento Especializado à Mulher

1. Introdução	3	Penalidade de capacidade	13
2. Problema escolhido	3	Penalidade de prazo hormonal	13
3. Objetivos do projeto	4	Penalidade de duração máxima	13
4. Visão geral da solução	5	Penalidade de compatibilidade veículo/carga	13
5. Arquitetura do sistema	5	11. Simulação operacional das rotas	14
6. Modelagem dos dados	7	12. Visualização e interface	14
7. Frota utilizada	9	13. Integração com LLM	15
8. Representação da solução	10	14. Experimentos	17
9. Algoritmo genético	10	15. Testes automatizados	18
Operadores genéticos	12	16. Considerações éticas e de segurança	19
10. Função fitness	12	17. Limitações	20
Penalidade de prioridade	13	18. Possíveis evoluções	20
Penalidade de janela de horário	13	19. Conclusão	21

1. Introdução

Este relatório apresenta a solução desenvolvida para o Tech Challenge da Fase 2 da pós-graduação em IA para Devs da FIAP. O projeto implementa um sistema de otimização de rotas voltado à distribuição de medicamentos e ao atendimento especializado à mulher, utilizando algoritmo genético, dados sintéticos, visualização geográfica e integração com LLM para apoio operacional.

A aplicação foi construída para simular um cenário em que uma central de distribuição precisa organizar atendimentos de diferentes tipos, com níveis de prioridade, janelas de horário, demandas de suprimentos e restrições específicas de transporte. A solução busca gerar uma distribuição operacionalmente viável das visitas entre veículos da frota, considerando restrições relevantes para o contexto de saúde da mulher.

O sistema não tem a finalidade de substituir decisões clínicas, protocolos oficiais ou profissionais de saúde. Seu objetivo é apoiar a análise logística e operacional por meio de uma abordagem computacional reproduzível.

2. Problema escolhido

O projeto implementa o **Projeto 2: otimização de rotas para distribuição de medicamentos e atendimento especializado à mulher**.

O problema consiste em organizar uma sequência de visitas para atender pontos com diferentes demandas, respeitando restrições como prioridade, janelas de horário e capacidade de transporte. O cenário foi modelado com dados sintéticos, representando uma central de distribuição e pontos de atendimento espalhados geograficamente.

Os tipos de atendimento considerados são:

Tipo de atendimento	Prioridade	Descrição operacional
Emergência obstétrica	1	Atendimento de maior urgência
Violência doméstica	2	Atendimento sensível, com necessidade de discrição e segurança
Medicamento hormonal	3	Entrega com prazo máximo de transporte e preferência por veículo refrigerado
Atendimento pós-parto	4	Atendimento programado com janela de horário

Quanto menor o valor numérico da prioridade, maior é a criticidade do atendimento.

3. Objetivos do projeto

O objetivo principal do projeto é desenvolver uma aplicação capaz de otimizar rotas de atendimento especializado à mulher, considerando restrições operacionais e assistenciais.

Os objetivos específicos são:

- carregar dados sintéticos de central e pontos de atendimento;
- representar diferentes tipos de atendimento e prioridades;
- utilizar algoritmo genético para gerar soluções otimizadas;
- distribuir pontos de atendimento entre veículos com capacidades diferentes;
- considerar restrições de janela de horário, capacidade, prazo hormonal e duração máxima;
- penalizar incompatibilidades entre tipo de carga e veículo;
- visualizar a solução em mapa interativo;
- apresentar métricas, tabelas e resumos operacionais;
- gerar relatórios e respostas em linguagem natural por meio de LLM;
- validar componentes principais por meio de testes automatizados.

4. Visão geral da solução

A solução foi implementada em Python, com interface em Streamlit e visualização geográfica em Folium. O algoritmo genético trabalha sobre soluções candidatas que distribuem os pontos de atendimento entre os veículos disponíveis.

Cada solução contém uma rota para cada veículo. As rotas são avaliadas individualmente e, em seguida, consolidadas em métricas gerais da frota. A avaliação considera a distância percorrida e penalidades associadas às restrições do problema.

A aplicação permite ao usuário configurar parâmetros do algoritmo genético, ajustar pesos da função fitness, alterar limites operacionais e configurar características da frota, como capacidade e velocidade média dos veículos.

A interface apresenta:

- métricas gerais da solução;
- mapa principal com rotas por veículo;
- legenda de veículos e prioridades;
- tabela consolidada da frota;
- resumo operacional por veículo;
- resumo textual determinístico;
- evolução do fitness;
- resultados de experimentos;
- relatórios e perguntas com LLM.

5. Arquitetura do sistema

A arquitetura foi organizada em camadas, separando domínio, dados, otimização, visualização, interface e integração com LLM.




Figura - Arquitetura geral do sistema.

A camada de dados carrega os arquivos CSV com a central de distribuição e os pontos de atendimento. A camada de domínio define as entidades principais, como pontos, veículos, rotas de veículos e solução de frota. A camada de otimização executa o algoritmo genético, simula as rotas e calcula a função fitness. A interface em Streamlit apresenta os resultados e permite interação com os parâmetros. A camada de LLM utiliza o contexto estruturado da frota para gerar relatórios e responder perguntas.

Essa separação facilita a manutenção do projeto, a execução de testes e a evolução da solução.

6. Modelagem dos dados

A modelagem dos dados representa os principais elementos do problema logístico: central de distribuição, pontos de atendimento, veículos, rotas, simulações e resultado da otimização.




Figura - Modelo de domínio e dados.

As principais entidades são:

Entidade	Papel no sistema
DistributionCenter	Representa a central de distribuição
AttendancePoint	Representa um ponto de atendimento ou entrega
Vehicle	Representa um veículo da frota
VehicleRoute	Representa a rota atribuída a um veículo
FleetSolution	Representa uma solução completa com múltiplas rotas
RouteStop	Representa uma parada simulada, com horários e status
RouteSimulation	Representa o resultado da simulação de uma rota
OptimizationResult	Representa o resultado final do algoritmo genético

Cada ponto possui coordenadas, tipo de atendimento, prioridade, demanda de suprimentos e janela de horário. Cada veículo possui capacidade, tipo, velocidade média e indicação de refrigeração.

7. Frota utilizada

A aplicação considera uma frota heterogênea composta por três tipos de veículos:

Veículo	Capacidade padrão	Refrigerado	Uso operacional
Moto de atendimento	8	Não	Atendimentos com menor volume de suprimentos
Veículo refrigerado	20	Sim	Transporte de medicamentos hormonais
Van operacional	30	Não	Atendimentos com maior demanda de suprimentos

A capacidade e a velocidade média de cada veículo podem ser ajustadas na sidebar da aplicação. A refrigeração é tratada como característica fixa do tipo de veículo.

Essa modelagem permite avaliar não apenas a ordem das visitas, mas também a adequação entre carga, veículo e restrições operacionais.

8. Representação da solução

No algoritmo genético, cada indivíduo representa uma solução completa para a frota. Em vez de uma única sequência de pontos, a solução contém uma lista de rotas, uma para cada veículo.

Exemplo conceitual:

```
FleetSolution
├─ V001: [P004, P001, P005, P008]
├─ V002: [P003, P011, P012, P010, P009]
└─ V003: [P006, P002, P018, P007, P020]
```

Cada ponto de atendimento deve aparecer exatamente uma vez na solução. Para garantir isso, foram criadas funções de validação que verificam se não há pontos duplicados, ausentes ou inesperados.

A duração operacional da frota é calculada como a maior duração entre as rotas dos veículos, pois as rotas são executadas em paralelo.

9. Algoritmo genético

O algoritmo genético é responsável por gerar e evoluir soluções candidatas até encontrar uma configuração com menor fitness.




Figura - Fluxo do algoritmo genético.

O processo segue as etapas:

1. Carregamento da central, dos pontos de atendimento e da frota.
2. Geração da população inicial de soluções.
3. Validação das soluções para garantir que cada ponto aparece uma única vez.
4. Avaliação da população pela função fitness.
5. Ordenação das soluções pelo menor fitness.
6. Preservação da elite.
7. Seleção de pais.
8. Aplicação de crossover de frota.
9. Aplicação de mutação.
10. Validação dos filhos gerados.
11. Reavaliação e atualização da melhor solução.
12. Registro do histórico de fitness.

Operadores genéticos

Os operadores foram adaptados para lidar com soluções compostas por múltiplas rotas.

A geração inicial distribui os pontos entre os veículos. Pontos de medicamento hormonal são preferencialmente atribuídos ao veículo refrigerado.

O crossover preserva parte das rotas de um pai e completa a solução com pontos do outro pai, mantendo a unicidade dos pontos.

A mutação pode ocorrer de três formas:

- troca de pontos dentro da mesma rota;
- movimentação de um ponto entre veículos;
- troca de pontos entre veículos.

Essas operações permitem explorar diferentes distribuições e ordens de atendimento.

10. Função fitness

A função fitness mede a qualidade de uma solução. Quanto menor o valor, melhor a solução encontrada.

A composição geral é:

```
fitness =  
  distância total da frota  
  + penalidade de prioridade  
  + penalidade de janela de horário  
  + penalidade de capacidade  
  + penalidade de prazo hormonal  
  + penalidade de duração máxima  
  + penalidade de compatibilidade veículo/carga
```

Penalidade de prioridade

A penalidade de prioridade incentiva o algoritmo a tratar atendimentos mais críticos com maior relevância no planejamento. A prioridade 1 representa o maior nível de urgência.

Penalidade de janela de horário

Cada ponto possui uma janela de horário. Se o veículo chega antes da janela, o sistema registra espera. Se chega depois do fim da janela, o sistema registra atraso e aplica penalidade.

Penalidade de capacidade

Cada veículo possui capacidade individual. Quando a demanda atribuída a uma rota excede a capacidade do veículo, a solução recebe penalidade proporcional ao excesso.

Penalidade de prazo hormonal

Medicamentos hormonais possuem prazo máximo de transporte contado desde a saída da central. Se a entrega ocorre após o limite configurado, a solução recebe penalidade proporcional ao atraso.

Penalidade de duração máxima

Cada rota possui duração máxima operacional. Se a duração de uma rota ultrapassa o limite, é aplicada penalidade ao excesso.

Penalidade de compatibilidade veículo/carga

Medicamentos hormonais devem ser preferencialmente transportados por veículo refrigerado. Quando um ponto desse tipo é atribuído a veículo sem refrigeração, a solução recebe penalidade de compatibilidade.

11. Simulação operacional das rotas

A simulação calcula os horários estimados de cada rota com base na sequência de pontos, na localização da central, na velocidade média do veículo e nas janelas de horário.

Para cada parada, são calculados:

- distância desde o ponto anterior;
- horário estimado de chegada;
- horário de início do atendimento;
- janela de horário;
- tempo de espera;
- atraso;
- tempo desde a saída da central;
- status do prazo hormonal.

Ao final de cada rota, também são calculados:

- horário estimado de retorno à central;
- duração total da rota;
- distância total da rota;
- distância do trecho de retorno.

Essas informações alimentam a função fitness, a tabela operacional, os popups do mapa e o contexto enviado à LLM.

12. Visualização e interface

A interface foi construída com Streamlit. O mapa principal utiliza Folium para representar visualmente as rotas dos veículos.

Cada cor representa um veículo da frota. Cada marcador exibe a ordem da parada e a prioridade do atendimento, permitindo interpretar a solução sem abrir os detalhes individuais. A legenda apresenta a relação entre cores, veículos e níveis de prioridade.

A interface também apresenta:

- resumo da solução com frota;

- penalidades aplicadas;
- mapa operacional em destaque;
- roteiro consolidado da frota;
- resumo por veículo;
- resumo textual;
- evolução do fitness;
- comparação de experimentos;
- integração com LLM.

A sidebar permite configurar parâmetros do algoritmo genético, operação da frota, pesos da função fitness e integração com Ollama.

13. Integração com LLM

A aplicação utiliza LLM via API do Ollama para transformar os dados estruturados da solução em textos operacionais.




Figura - Fluxo de integração com LLM.

A LLM recebe um contexto textual estruturado da frota, contendo:

- resumo geral da solução;
- rotas por veículo;
- horários estimados;
- prioridades;
- status de janela;
- status do prazo hormonal;
- capacidade por veículo;
- penalidades e violações.

Foram implementados três tipos de prompt:

Prompt	Finalidade
<code>instruction_manual.md</code>	Geração de manual de instruções
<code>visit_plan.md</code>	Geração de roteiro detalhado de visitas
<code>route_question.md</code>	Resposta a perguntas sobre a frota

Os prompts orientam a LLM a usar apenas os dados fornecidos, não recalculando informações, não inventar dados e não expor informações sensíveis.

Exemplos de perguntas suportadas:

```
Qual veículo atende os medicamentos hormonais?  
A frota ultrapassou a duração máxima?  
Algum veículo excedeu a capacidade?  
Qual é o próximo atendimento prioritário?
```

14. Experimentos

O projeto inclui um script para execução de experimentos comparativos do algoritmo genético.

```
python experiments/run_experiments.py
```

Os resultados são salvos em:

```
outputs/experiments_results.csv
```

Os experimentos variam parâmetros como:

- tamanho da população;
- número de gerações;
- probabilidade de mutação;
- elitismo;
- uso de seed fixa ou aleatória.

As métricas salvas incluem:

- fitness final;
- fitness inicial;
- melhoria do fitness;
- distância total da frota;
- duração operacional;
- penalidade de prioridade;
- penalidade de janela;
- penalidade de capacidade;
- penalidade de prazo hormonal;
- penalidade de duração máxima;
- penalidade de compatibilidade;
- demanda total;
- quantidade de veículos;
- veículo com maior duração;
- sequência das rotas por veículo.

A aba de experimentos da aplicação permite comparar os resultados em tabela e gráficos.

15. Testes automatizados

O projeto possui testes automatizados com Pytest.

A suíte cobre:

- carregamento dos dados;
- cálculo de distâncias;
- simulação das rotas;
- cálculo das penalidades;
- geração da frota padrão;
- geração da população inicial;
- validação de soluções de frota;
- crossover de frota;
- mutação de frota;
- avaliação da solução otimizada;
- compatibilidade entre veículo e carga.

Os testes podem ser executados com:

```
pytest
```

A presença dos testes ajuda a garantir que alterações no algoritmo, na modelagem ou nas penalidades não quebrem regras essenciais do problema.

16. Considerações éticas e de segurança

O projeto aborda um contexto sensível de saúde da mulher, incluindo violência doméstica, emergência obstétrica, medicamentos hormonais e pós-parto. Por isso, a solução foi desenhada com cuidados específicos.

A aplicação não utiliza dados pessoais reais. Os dados são sintéticos e servem apenas para simulação acadêmica.

A LLM é orientada a não fornecer diagnóstico médico, não substituir protocolos oficiais e não expor informações sensíveis além do necessário para a operação.

Em um cenário real, seria necessário aplicar controles adicionais, como:

- anonimização de dados;
- controle de acesso;
- auditoria de uso;

- criptografia de dados sensíveis;
 - validação com profissionais da área;
 - conformidade com a LGPD;
 - integração com protocolos institucionais.
-

17. Limitações

A solução possui limitações importantes:

- os dados utilizados são sintéticos;
- o tempo de atendimento é simplificado;
- o trânsito real não é considerado;
- não há replanejamento em tempo real;
- não há múltiplas centrais de distribuição;
- a disponibilidade de equipes não é modelada;
- os veículos são definidos de forma simplificada;
- a LLM atua apenas como apoio textual e não altera a solução otimizada.

Essas limitações são compatíveis com o escopo acadêmico do projeto, mas devem ser consideradas em qualquer tentativa de aplicação real.

18. Possíveis evoluções

Como melhorias futuras, podem ser consideradas:

- integração com APIs reais de trânsito;
- reotimização dinâmica durante a operação;
- cadastro dinâmico de veículos;
- múltiplas centrais de distribuição;
- restrições de jornada de trabalho;
- diferentes tempos de atendimento por tipo;
- restrições de segurança para casos sensíveis;
- integração com sistemas hospitalares;
- monitoramento em tempo real;

- comparação com outras heurísticas de otimização;
- uso de previsão de demanda.

Também seria possível ampliar o uso da LLM para gerar análises comparativas entre cenários, desde que a decisão final continue baseada nos dados estruturados e nas regras da aplicação.

19. Conclusão

O projeto implementa uma solução de otimização de rotas para distribuição de medicamentos e atendimento especializado à mulher, considerando restrições operacionais relevantes para o contexto proposto.

A aplicação combina algoritmo genético, modelagem de frota, simulação operacional, visualização em mapa e integração com LLM. A solução permite configurar parâmetros, comparar experimentos, visualizar rotas por veículo e gerar textos operacionais a partir dos dados otimizados.

A abordagem desenvolvida demonstra como técnicas de inteligência artificial e otimização podem apoiar problemas logísticos em saúde, desde que utilizadas com responsabilidade, transparência e respeito aos limites éticos e institucionais.